

Fundamentos para la construcción, validación y exploración de una base horaria de contaminación atmosférica

1. Objetivo y estructura de los datos

El notebook construye una base de concentraciones horarias de ozono, partículas PM_{10} y partículas $\text{PM}_{2.5}$ para el periodo 2015–2025. Su propósito es preparar y explorar los datos antes de definir episodios extremos o desarrollar modelos de anticipación.

Cada medición puede identificarse mediante tres elementos: el contaminante, la estación y la posición temporal.

Denotaremos por

$$X_{c,s,t}$$

la concentración del contaminante c , registrada en la estación s , durante la posición horaria t .

Para un contaminante fijo podemos omitir el subíndice c y escribir simplemente $X_{s,t}$.

La base conjunta tiene una fila por hora y una columna por combinación de contaminante y estación. Las redes seleccionadas contienen nueve estaciones para O_3 , tres para PM_{10} y cuatro para $\text{PM}_{2.5}$.

Por tanto, el número de variables es

$$9 + 3 + 4 = 16.$$

Esto no significa que existan 16 ubicaciones distintas: una estación puede medir varios contaminantes. Por ejemplo, O_3 en MER y PM_{10} en MER son variables diferentes registradas en la misma ubicación.

2. Calendario e índice temporal

2.1. Resolución horaria

Una serie temporal horaria consiste en observaciones organizadas sobre posiciones separadas por una hora:

$$t_1, t_2, \dots, t_N, \quad t_{i+1} - t_i = 1 \text{ hora.}$$

La regularidad del calendario permite interpretar correctamente rezagos, rachas y ventanas temporales.

Si se eliminan las filas con datos faltantes, dos filas consecutivas podrían representar horas separadas por varios intervalos. Por ello, conviene conservar el calendario completo y representar explícitamente las ausencias.

2.2. Número de horas esperadas

Un año común contiene

$$365 \times 24 = 8760$$

posiciones horarias. Un año bisiesto contiene

$$366 \times 24 = 8784.$$

Entre 2015 y 2025 hay ocho años comunes y tres bisiestos: 2016, 2020 y 2024. El calendario utilizado contiene

$$N = 8(8760) + 3(8784) = 96432$$

posiciones horarias, correspondientes a

$$D = \frac{96432}{24} = 4018$$

días.

Este conteo corresponde al calendario interno de 24 códigos por día. No establece todavía cómo deben interpretarse esos códigos frente a una zona horaria o a posibles cambios de horario civil.

2.3. Construcción de la referencia interna

Los archivos contienen una fecha y un código horario entre 1 y 24. En el notebook se utiliza

$$t_{\text{interno}} = \text{FECHA} + (\text{HORA} - 1) \text{ horas.}$$

Por ejemplo:

$$(2024-04-06, 1) \mapsto 2024-04-06 \text{ 00:00,}$$

$$(2024-04-06, 24) \mapsto 2024-04-06 \text{ 23:00.}$$

Esta transformación proporciona una referencia ordenada y consistente. Sin embargo, no confirma si el código original representa el inicio o el final de un intervalo de medición.

La convención de la fuente debe verificarse antes de relacionar las concentraciones con eventos externos.

2.4. Validación temporal

La auditoría temporal comprueba que:

- Las fechas sean interpretables y pertenezcan al año esperado.
- Los códigos horarios sean enteros entre 1 y 24.
- No existan combinaciones duplicadas de fecha y hora.
- Los registros estén ordenados.
- Se identifiquen las posiciones ausentes del calendario.

Tener el número esperado de filas no garantiza que estén presentes todas las horas. Una hora duplicada y otra ausente podrían producir el conteo correcto.

Si T_{esperado} es el calendario y $T_{\text{observado}}$ contiene las marcas temporales existentes, las horas ausentes son

$$T_{\text{ausente}} = T_{\text{esperado}} \setminus T_{\text{observado}}.$$

3. Datos faltantes y trazabilidad

3.1. Tipos de ausencia

Es necesario distinguir entre:

1. **Fila ausente:** no existe un registro para una hora.
2. **Celda vacía:** existe la fila, pero falta el valor de una estación.
3. **Código de ausencia:** existe la fila y contiene el código -99 .
4. **Valor cero:** existe una medición numérica igual a cero.

Un cero no debe tratarse automáticamente como ausencia. Su interpretación depende de la documentación de la fuente.

3.2. Representación mediante NaN

El código -99 se sustituye por NaN, una representación computacional de un valor faltante. No es una concentración y no debe participar como número en promedios o comparaciones. Por ejemplo, para dos mediciones 20 y 30 y un código -99 , la operación

$$\frac{20 + 30 - 99}{3}$$

produce un resultado incorrecto. El promedio de las dos mediciones disponibles es

$$\frac{20 + 30}{2} = 25.$$

3.3. Calendario completo e imputación

Agregar una posición temporal ausente y asignarle NaN completa la estructura del calendario. Imputar consiste en estimar un valor:

$$X_{s,t} \text{ faltante} \longrightarrow \hat{X}_{s,t}.$$

Son operaciones distintas. El notebook completa el calendario, pero no estima concentraciones ausentes.

3.4. Conservar el origen de los faltantes

Una vez que varias causas se representan con NaN, la base numérica ya no permite distinguirlas por sí sola.

Por ello, se conserva una tabla paralela de estados:

$$E_{s,t} \in \{\text{OBSERVADO}, \text{CODIGO_MENOS_99}, \text{CELDA_VACIA}, \text{FILA_AUSENTE}\}.$$

Esta tabla mantiene la trazabilidad de la preparación.

3.5. Disponibilidad y calidad

Una medición numérica finita distinta de -99 cumple el criterio de disponibilidad utilizado en el notebook.

Eso no certifica su calidad instrumental. La validación de una medición puede requerir información sobre calibración, mantenimiento, banderas de calidad y procedimientos de la fuente.

Además, las ausencias pueden concentrarse en ciertos periodos. En ese caso, la distribución de las observaciones disponibles puede diferir de la distribución del calendario completo.

4. Disponibilidad individual y de la red

4.1. Indicador de observación

Definimos

$$I_{s,t} = \begin{cases} 1, & \text{si la estación } s \text{ tiene una medición disponible en } t, \\ 0, & \text{si su medición es faltante.} \end{cases}$$

La disponibilidad individual de la estación s es

$$A_s = 100 \frac{\sum_{t=1}^N I_{s,t}}{N}.$$

El denominador incluye todas las posiciones del calendario, también las horas sin fila original.

4.2. Número de estaciones disponibles

Para una red con S estaciones:

$$K_t = \sum_{s=1}^S I_{s,t}.$$

Así, K_t puede tomar valores entre cero y S .

El porcentaje de horas con al menos k estaciones disponibles es

$$A_{\geq k} = \frac{100}{N} \sum_{t=1}^N \mathbf{1}\{K_t \geq k\},$$

donde $\mathbf{1}\{\cdot\}$ es la función indicadora: vale uno cuando se cumple la condición y cero en otro caso.

En particular,

$$A_{\geq 1}$$

mide la disponibilidad de alguna estación, mientras que

$$A_{\text{todas}} = \frac{100}{N} \sum_{t=1}^N \mathbf{1}\{K_t = S\}$$

mide la disponibilidad simultánea de toda la red.

Una red puede tener alguna estación disponible casi siempre, pero pocas horas con todas sus estaciones disponibles.

4.3. Distribución de disponibilidad

El porcentaje de horas con exactamente j estaciones es

$$p_j = \frac{100}{N} \sum_{t=1}^N \mathbf{1}\{K_t = j\}.$$

Estas categorías son mutuamente excluyentes y cubren el calendario:

$$\sum_{j=0}^S p_j = 100.$$

4.4. Rachas sin red

Una racha sin red es un bloque consecutivo de horas con $K_t = 0$.

Si sus longitudes son $L_1, \dots, L_m$, la mayor racha es

$$L_{\text{máx}} = \text{máx}(L_1, \dots, L_m).$$

Su duración expresada en días es

$$\frac{L_{\text{máx}}}{24}.$$

La proporción de horas sin red y la mayor racha describen aspectos diferentes: cantidad total de ausencia y continuidad de esa ausencia.

5. Estadísticos descriptivos

Sea $x_1, \dots, x_n$ el conjunto de concentraciones disponibles de una estación dentro del periodo analizado.

5.1. Media y desviación estándar

La media es

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

La desviación estándar muestral es

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

La media describe el nivel promedio y la desviación estándar la dispersión alrededor de ese promedio.

Ambas pueden ser sensibles a observaciones muy altas.

5.2. Mediana

Si las observaciones ordenadas son

$$x_{(1)} \leq \cdots \leq x_{(n)},$$

la mediana es

$$\tilde{x} = \begin{cases} x_{((n+1)/2)}, & n \text{ impar}, \\ \frac{x_{(n/2)} + x_{(n/2+1)}}{2}, & n \text{ par}. \end{cases}$$

Es una medida de posición central menos sensible a extremos que la media.

Una media mayor que la mediana es compatible con una distribución extendida hacia valores altos, pero no constituye por sí sola una descripción completa de su forma.

5.3. Cuantiles y percentiles

Un cuantil $Q(q)$ identifica una posición de la distribución, con $0 \leq q \leq 1$.

El percentil 95 corresponde a $Q(0.95)$ y la mediana a $Q(0.50)$.

Con la interpolación lineal utilizada en los cálculos del notebook, se obtiene

$$h = 1 + (n - 1)q.$$

Si $j = \lfloor h \rfloor$ y $\alpha = h - j$, entonces, para $q < 1$,

$$Q(q) = (1 - \alpha)x_{(j)} + \alpha x_{(j+1)}.$$

Para $q = 1$, se utiliza $Q(1) = x_{(n)}$.

Esto explica por qué un percentil puede ser decimal aunque las concentraciones originales sean enteras.

5.4. Rango intercuartílico

El rango intercuartílico es

$$RIC = Q(0.75) - Q(0.25).$$

Describe la amplitud de la mitad central de la distribución.

El intervalo entre esos cuantiles describe dispersión de las observaciones; no es un intervalo de confianza de la mediana.

5.5. Máximos

El máximo es

$$x_{\text{máx}} = \text{máx}(x_1, \dots, x_n).$$

Puede estar determinado por pocas observaciones. Es diferente del percentil 95, que describe una posición de la distribución.

Un máximo elevado no demuestra automáticamente un error. Su revisión requiere contexto temporal, espacial y documental.

6. Representación de distribuciones y extremos

6.1. Diagrama de caja

En la figura del notebook:

- La caja representa $Q(0.25)$ a $Q(0.75)$.
- La línea interior representa la mediana.
- El rombo representa la media.
- Los bigotes alcanzan observaciones próximas a P1 y P99.
- El triángulo representa el máximo.

Esta definición de bigotes difiere de la regla habitual basada en $1.5 RIC$.

Ocultar puntos externos a los bigotes evita saturación visual; no elimina esas observaciones de la base.

6.2. Contexto temporal del máximo

Si el máximo ocurre en t^* , se revisan:

$$X_{s,t^*-1}, \quad X_{s,t^*}, \quad X_{s,t^*+1}.$$

La comparación utiliza horas consecutivas del calendario. Si una hora vecina es faltante, debe conservarse como tal.

Eliminar primero los faltantes podría comparar el máximo con una observación separada por varias horas.

6.3. Contexto espacial

También se examinan las demás estaciones disponibles en t^* .

La estación evaluada se excluye del resumen de referencia para evitar que su propio máximo influya en la comparación.

La coincidencia de aumentos en varias estaciones aporta contexto, pero no identifica una causa ni certifica la calidad de los datos.

7. Perfiles horarios, mensuales y anuales

7.1. Perfil por código horario

Sea

$$T_h = \{t : \text{el código horario de } t \text{ es } h\}.$$

La mediana horaria de una estación es

$$M_{s,h} = \text{mediana}\{X_{s,t} : t \in T_h, I_{s,t} = 1\}.$$

Cada punto reúne mediciones de muchos días. La curva de medianas no representa un día particular.

Su disponibilidad es

$$A_{s,h} = 100 \frac{\sum_{t \in T_h} I_{s,t}}{|T_h|}.$$

En este calendario, $|T_h| = 4018$ para cada código horario.

7.2. Perfil por mes del calendario

Sea

$$T_m = \{t : \text{el mes de } t \text{ es } m\}.$$

La mediana mensual agrupada es

$$M_{s,m} = \text{mediana}\{X_{s,t} : t \in T_m, I_{s,t} = 1\}.$$

Por ejemplo, abril reúne las mediciones de todos los abrils de 2015–2025.

Esto es distinto de estudiar abril de 2024 como periodo individual.

La disponibilidad correspondiente es

$$A_{s,m} = 100 \frac{\sum_{t \in T_m} I_{s,t}}{|T_m|}.$$

El denominador depende de la duración del mes y de los años bisiestos.

7.3. Resúmenes anuales

Los resúmenes anuales se calculan restringiendo las observaciones a un año específico.

Permiten examinar cambios que los perfiles agregados pueden ocultar. Sin embargo, una secuencia de medianas crecientes o decrecientes no constituye por sí sola una prueba de tendencia.

Las diferencias de cobertura pueden cambiar la composición de meses y horas observadas en cada año.

7.4. Agrupar no significa cambiar la base

Calcular medianas por mes o año no transforma las mediciones originales en promedios diarios.

La base mantiene su resolución horaria; los resúmenes son productos descriptivos adicionales.

Además, al agrupar todas las mediciones disponibles, cada observación tiene el mismo peso. Los años con más datos aportan más observaciones al resumen conjunto.

8. Comparaciones en horas compartidas

8.1. Conjunto de comparación

Para las estaciones A y B:

$$T_{AB} = \{t : I_{A,t} = 1, I_{B,t} = 1\}.$$

Las comparaciones utilizan exclusivamente este conjunto.

Así se evita comparar directamente estadísticas construidas sobre fechas diferentes para A y B. No obstante, las horas excluidas pueden seguir limitando la representatividad del resultado.

Cada par puede tener un conjunto T_{AB} diferente.

8.2. Correlación de Pearson

Sobre las n horas compartidas, la correlación de Pearson es

$$r_{AB} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}.$$

Mide asociación lineal y toma valores entre -1 y 1 .

No está definida cuando alguna serie carece de variación.

Una correlación alta no implica concentraciones iguales. Por ejemplo, si $Y = X + 10$ y X tiene variación, la correlación es uno, aunque las concentraciones difieran en diez unidades.

8.3. Correlación de Spearman

Spearman se calcula como Pearson sobre los rangos:

$$\rho_S = \text{Corr}(R(X), R(Y)).$$

Los empates reciben rangos promedio.

Describe asociación monótona: valores mayores de una variable tienden a acompañarse de valores mayores o menores de la otra, sin exigir una relación lineal.

8.4. Diferencias por hora

Se define

$$D_t = X_{B,t} - X_{A,t}.$$

La mediana de D_t describe una diferencia central entre estaciones en las mismas horas.

En general,

$$\text{mediana}(X_B - X_A) \neq \text{mediana}(X_B) - \text{mediana}(X_A).$$

8.5. Dependencia temporal y patrones comunes

Las observaciones horarias pueden depender de sus valores previos:

$$\text{Cov}(X_t, X_{t-k}) \neq 0.$$

Además, dos estaciones pueden compartir patrones horarios o anuales que contribuyan a su correlación.

Por ello, una correlación calculada sobre toda la serie no describe exclusivamente la asociación entre variaciones inesperadas.

No deben aplicarse automáticamente pruebas que traten todas las horas como observaciones independientes.

9. Faltantes y modelos de anticipación

9.1. Separar mediciones, etiquetas y predictores

La base preparada conserva las mediciones y sus ausencias.

Posteriormente deberán distinguirse:

- **Etiquetas:** indican qué episodio ocurrió.

- **Predictores:** información disponible para anticiparlo.
- **Imputaciones:** estimaciones de datos ausentes.

Una concentración imputada no debe tratarse automáticamente como evidencia observada de presencia o ausencia de un episodio.

Cuando falte información suficiente, una etiqueta puede quedar indeterminada.

9.2. Información futura

Una predicción realizada en t debe usar información disponible hasta ese momento:

$$\hat{Y}_{t+h} = f(\mathcal{F}_t),$$

donde $\mathcal{F}_t$ representa esa información.

Interpolar un predictor utilizando una observación posterior a t introduce información futura.

Asimismo, los parámetros de imputación, escalamiento o umbrales aprendidos deben ajustarse con el conjunto de entrenamiento, no con toda la serie antes de evaluar el modelo.

9.3. Exploración y selección retrospectiva

El notebook explora todo el periodo 2015–2025. Sus resúmenes no deben convertirse automáticamente en parámetros del futuro modelo.

Las redes también fueron seleccionadas mediante información del periodo completo. Esa decisión debe documentarse al diseñar la evaluación: caracteriza una selección retrospectiva y no reproduce por sí sola una decisión tomada únicamente con datos disponibles al inicio del periodo.

10. Reproducibilidad y alcance de la validación

10.1. Productos separados

La preparación conserva:

1. Concentraciones.
2. Estados de las celdas.
3. Información temporal y disponibilidad.
4. Diccionario de variables.
5. Auditorías, resúmenes y configuración.

Esta separación permite reutilizar la base y reconstruir las decisiones aplicadas.

10.2. Verificación de exportación

Leer nuevamente las tablas permite comprobar que se conservaron índices, columnas, valores, faltantes y estados.

Las huellas SHA-256 identifican el contenido de los archivos y permiten detectar modificaciones posteriores.

No certifican la calidad científica ni la corrección de las mediciones originales.

10.3. Precisión numérica

Los cálculos computacionales pueden producir diferencias muy pequeñas por la representación de números decimales.

Por ello, la comparación de indicadores puede utilizar:

$$|a - b| \leq \varepsilon,$$

con una tolerancia pequeña y adecuada al cálculo.

Una diferencia del orden de 10^{-14} entre porcentajes recalculados no representa un cambio material en la disponibilidad.

10.4. Qué quedó validado

Se verificaron la estructura de los archivos, la organización temporal, el tratamiento de faltantes y la conservación de los resultados durante la integración y exportación.

Permanecen pendientes de confirmación documental: las unidades, la zona horaria, el significado del intervalo y el estado de validación instrumental.

La exploración realizada no define todavía episodios extremos, no identifica causas de los aumentos y no evalúa capacidad de anticipación.