

# Detección temprana de episodios extremos de contaminación atmosférica mediante modelos probabilísticos y aprendizaje automático

Proyecto de Tesis

## 1. Introducción y motivación

La contaminación atmosférica representa uno de los principales problemas ambientales y de salud pública en zonas urbanas. La exposición a concentraciones elevadas de contaminantes como material particulado fino  $PM_{2,5}$ ,  $PM_{10}$ , ozono troposférico  $O_3$ , dióxido de nitrógeno  $NO_2$ , dióxido de azufre  $SO_2$  y monóxido de carbono  $CO$  se asocia con efectos adversos en la salud respiratoria y cardiovascular, además de impactos sociales y económicos.

En ciudades altamente urbanizadas, los episodios extremos de contaminación suelen estar asociados con una combinación de factores meteorológicos, emisiones locales, condiciones de estabilidad atmosférica, radiación solar, temperatura, humedad relativa, velocidad del viento y fenómenos estacionales. Estos eventos pueden presentar una dinámica compleja, no lineal y no estacionaria, lo cual dificulta su detección temprana mediante modelos estadísticos clásicos.

Desde el punto de vista de las Matemáticas Aplicadas, el problema puede formularse como una tarea de detección temprana de anomalías o eventos extremos en series temporales multivariadas. En este contexto, resulta natural combinar herramientas de modelación probabilística, análisis de cambio de régimen, aprendizaje automático y evaluación predictiva.

El objetivo central de este proyecto es desarrollar y evaluar una metodología computacional para detectar de manera temprana episodios extremos de contaminación atmosférica utilizando datos reales de estaciones de monitoreo ambiental y variables meteorológicas. El proyecto busca comparar métodos clásicos y modernos, cuantificar su desempeño bajo criterios reproducibles y generar resultados con potencial para derivar en un artículo de investigación aplicada.

## 2. Objetivos

### 2.1. Objetivo general

Desarrollar y evaluar un esquema metodológico para la detección temprana de episodios extremos de contaminación atmosférica en series temporales multivariadas, combinando modelos probabilísticos, métodos de cambio de régimen y técnicas de aprendizaje automático.

### 2.2. Objetivos específicos

1. Construir una base de datos multivariada a partir de registros horarios o diarios de contaminantes atmosféricos y variables meteorológicas.
2. Realizar un análisis exploratorio de las series temporales, identificando patrones estacionales, tendencias, ciclos diarios, dependencia temporal, valores extremos y posibles cambios de régimen.
3. Definir criterios operativos para caracterizar episodios extremos de contaminación, por ejemplo mediante umbrales basados en percentiles, normas ambientales o niveles críticos de concentración.
4. Implementar modelos base para detección de anomalías, tales como reglas basadas en umbrales, medias móviles, puntuaciones estandarizadas y métodos robustos como MAD o IQR.
5. Implementar métodos probabilísticos y de cambio de régimen, incluyendo CUSUM, BOCPD, modelos ocultos de Markov y segmentación temporal.
6. Implementar métodos de aprendizaje automático para detección de anomalías, tales como Isolation Forest, One-Class SVM, Random Forest, XGBoost o autoencoders.
7. Comparar el desempeño de los modelos mediante métricas como precisión, sensibilidad, especificidad, F1-score, falsas alarmas, retraso de detección y capacidad de anticipación.
8. Diseñar un flujo de trabajo reproducible en Python, incluyendo limpieza de datos, modelación, validación temporal, visualización de resultados y generación de tablas comparativas.
9. Identificar si la combinación de variables meteorológicas y contaminantes mejora la detección temprana frente a modelos univariados.

10. Elaborar un manuscrito derivado de la tesis con enfoque aplicado, orientado a revistas de ciencia de datos ambiental, modelación atmosférica o matemáticas aplicadas.

### 3. Marco teórico

#### 3.1. Series temporales atmosféricas

Una serie temporal atmosférica consiste en una sucesión de observaciones indexadas en el tiempo, por ejemplo

$$X_t = (X_{1,t}, X_{2,t}, \dots, X_{p,t}),$$

donde cada componente puede representar la concentración de un contaminante o una variable meteorológica en el tiempo  $t$ .

En este proyecto se considerarán series multivariadas formadas por contaminantes como

$$\text{PM}_{2.5}, \quad \text{PM}_{10}, \quad \text{O}_3, \quad \text{NO}_2, \quad \text{SO}_2, \quad \text{CO},$$

junto con variables meteorológicas como temperatura, humedad relativa, velocidad del viento, dirección del viento, presión atmosférica, radiación solar y precipitación.

Estas series pueden presentar estacionalidad diaria, semanal y anual, además de episodios extremos asociados con cambios meteorológicos o acumulación de contaminantes.

#### 3.2. Episodios extremos de contaminación

Un episodio extremo puede definirse como un periodo en el cual uno o varios contaminantes superan un umbral crítico. Matemáticamente, si  $Y_t$  representa la concentración de un contaminante, un evento extremo puede definirse mediante

$$Y_t > u,$$

donde  $u$  puede ser un umbral regulatorio, un percentil alto de la distribución histórica, por ejemplo el percentil 90 o 95, o un valor definido con base en criterios ambientales.

En el caso multivariado, puede considerarse una función de riesgo

$$R_t = g(X_t),$$

donde  $g$  resume la información de varios contaminantes y variables meteorológicas. Un epi-

sodio extremo ocurre cuando

$$R_t > u_R.$$

### 3.3. Detección de anomalías

La detección de anomalías busca identificar observaciones o periodos cuyo comportamiento se desvía significativamente del patrón esperado. En series temporales atmosféricas, una anomalía puede representar una concentración inusual, un incremento abrupto o una combinación atípica de condiciones meteorológicas y contaminantes.

Una estrategia básica consiste en calcular residuos

$$e_t = Y_t - \hat{Y}_t,$$

donde  $\hat{Y}_t$  es una predicción del comportamiento esperado. Si  $|e_t|$  supera cierto umbral, se declara una anomalía.

También pueden utilizarse puntuaciones normalizadas:

$$Z_t = \frac{Y_t - \mu_t}{\sigma_t},$$

donde  $\mu_t$  y  $\sigma_t$  representan una media y desviación estándar estimadas localmente o por temporada.

### 3.4. Métodos de cambio de régimen

Los métodos de cambio de régimen buscan detectar momentos en los cuales la distribución o dinámica de una serie cambia significativamente. En el contexto de contaminación atmosférica, estos cambios pueden representar transiciones hacia episodios de acumulación de contaminantes.

Entre los métodos considerados se encuentran:

- CUSUM, para detectar cambios acumulativos en la media.
- BOCPD, para detección bayesiana en línea de puntos de cambio.
- Modelos ocultos de Markov, para representar estados latentes de contaminación baja, moderada o alta.
- Segmentación penalizada, para dividir la serie en intervalos homogéneos.

En un modelo oculto de Markov, se supone que existe una variable latente  $S_t$  que representa el régimen atmosférico en el tiempo  $t$ . Por ejemplo,

$$S_t \in \{1, 2, 3\},$$

donde los estados pueden interpretarse como contaminación baja, media y alta. Las observaciones  $X_t$  dependen del estado oculto:

$$X_t \mid S_t = k \sim F_k.$$

### 3.5. Aprendizaje automático para detección temprana

Los métodos de aprendizaje automático permiten capturar relaciones no lineales entre contaminantes, meteorología y eventos extremos. En este proyecto se considerarán métodos supervisados y no supervisados.

Entre los métodos no supervisados destacan:

- Isolation Forest.
- One-Class SVM.
- Autoencoders.
- Clustering temporal.

Entre los métodos supervisados, si se construye una variable indicadora de episodio extremo,

$$Z_t = \begin{cases} 1, & \text{si ocurre un episodio extremo en } t, \\ 0, & \text{en otro caso,} \end{cases}$$

pueden emplearse modelos de clasificación como regresión logística, Random Forest, XGBoost o redes neuronales.

### 3.6. Evaluación de detección temprana

La evaluación no debe limitarse a clasificar correctamente eventos, sino también a determinar si el modelo detecta el episodio con suficiente anticipación.

Algunas métricas relevantes son:

- Precisión.

- Sensibilidad.
- Especificidad.
- F1-score.
- Número de falsas alarmas.
- Tiempo promedio de anticipación.
- Retraso de detección.

Si  $t_0$  es el inicio real de un episodio y  $\hat{t}$  es el tiempo en que el modelo emite una alerta, el retraso de detección puede definirse como

$$D = \hat{t} - t_0.$$

Un buen sistema debe tener alta sensibilidad y bajo retraso, evitando al mismo tiempo un número excesivo de falsas alarmas.

## 4. Metodología

### 4.1. Selección y construcción de la base de datos

Se recopilarán datos de estaciones de monitoreo ambiental y variables meteorológicas. La unidad temporal podrá ser horaria o diaria, dependiendo de la calidad y disponibilidad de los datos.

La base inicial tendrá la forma

$$\{X_t\}_{t=1}^T,$$

donde

$$X_t = (C_{1,t}, \dots, C_{m,t}, M_{1,t}, \dots, M_{q,t}),$$

con  $C_{i,t}$  contaminantes atmosféricos y  $M_{j,t}$  variables meteorológicas.

Se considerarán contaminantes como PM<sub>2,5</sub>, PM<sub>10</sub>, O<sub>3</sub>, NO<sub>2</sub>, SO<sub>2</sub> y CO. Las variables meteorológicas podrán incluir temperatura, humedad relativa, velocidad del viento, dirección del viento, presión atmosférica, radiación solar y precipitación.

### 4.2. Preprocesamiento

El preprocesamiento incluirá:

- Revisión de valores faltantes.
- Homologación de unidades y frecuencias temporales.
- Eliminación o imputación de registros anómalos por fallas de medición.
- Agregación horaria o diaria.
- Construcción de variables rezagadas.
- Construcción de variables móviles, por ejemplo medias de 8 o 24 horas.
- Estandarización de variables.

También se podrán construir variables temporales como hora del día, día de la semana, mes, temporada seca/lluviosa y variables indicadoras de fines de semana.

### 4.3. Definición de episodios extremos

Se definirán episodios extremos mediante una o varias estrategias:

- a) Umbrales normativos o de referencia ambiental.
- b) Percentiles altos de la distribución histórica, por ejemplo  $P_{90}$  o  $P_{95}$ .
- c) Índices compuestos de contaminación.
- d) Eventos multivariados definidos por la superación simultánea de varios umbrales.

Por ejemplo, para un contaminante  $Y_t$ , puede definirse

$$Z_t = \begin{cases} 1, & Y_t > Q_{0,95}(Y), \\ 0, & Y_t \leq Q_{0,95}(Y), \end{cases}$$

donde  $Q_{0,95}(Y)$  representa el percentil 95 de la serie histórica.

### 4.4. Modelos base

Se implementarán modelos simples como referencia:

- Umbrales fijos.
- Z-score.

- Media móvil y desviación móvil.
- Métodos robustos basados en mediana y MAD.
- Modelos autorregresivos simples.

Estos modelos servirán como línea base para evaluar si los métodos más complejos realmente aportan mejoras.

## 4.5. Métodos probabilísticos y de cambio de régimen

Se implementarán métodos orientados a detectar transiciones hacia estados de alta contaminación:

- CUSUM para cambios en la media.
- BOCPD para detección bayesiana en línea.
- Modelos ocultos de Markov para clasificar estados latentes.
- Segmentación temporal penalizada para detectar cambios estructurales.

En particular, se explorará si los estados latentes identificados por los modelos corresponden a regímenes interpretables de contaminación baja, moderada y alta.

## 4.6. Métodos de aprendizaje automático

Se evaluarán métodos no supervisados y supervisados.

En el enfoque no supervisado, se considerarán:

- Isolation Forest.
- One-Class SVM.
- Autoencoders.
- Clustering temporal.

En el enfoque supervisado, si se construyen etiquetas de episodios extremos, se evaluarán:

- Regresión logística.
- Random Forest.



- Gradient Boosting.
- XGBoost.
- Redes neuronales simples.

Los modelos podrán entrenarse con variables rezagadas:

$$X_t, X_{t-1}, \dots, X_{t-p},$$

con el objetivo de anticipar episodios extremos en horizontes futuros:

$$Z_{t+h}, \quad h = 1, 2, \dots, H.$$

## 4.7. Validación temporal

La evaluación se realizará mediante validación temporal, evitando mezclar información futura con información pasada. Se utilizarán esquemas como:

- Separación entrenamiento-prueba respetando el orden temporal.
- Validación rolling-origin.
- Backtesting por ventanas.

Este enfoque permitirá evaluar la capacidad real de detección temprana de los modelos.

## 4.8. Comparación de desempeño

Los modelos se compararán mediante métricas de clasificación y detección temprana:

- Accuracy.
- Precision.
- Recall.
- F1-score.
- Área bajo la curva ROC.
- Falsas alarmas por periodo.
- Retraso promedio de detección.

- Anticipación promedio del evento.

También se evaluará la interpretabilidad de los modelos mediante importancia de variables, análisis de sensibilidad y visualización de episodios detectados.

## 5. Resultados esperados

Se espera obtener:

1. Una base de datos limpia y reproducible de contaminantes atmosféricos y variables meteorológicas.
2. Una caracterización exploratoria de la dinámica temporal de los principales contaminantes.
3. Una definición operativa de episodios extremos de contaminación atmosférica.
4. Una comparación rigurosa entre modelos base, métodos probabilísticos, cambio de régimen y aprendizaje automático.
5. Evidencia sobre qué variables meteorológicas y contaminantes contribuyen más a la detección temprana.
6. Un sistema reproducible de alerta temprana experimental para episodios extremos.
7. Figuras y tablas listas para integrarse en un manuscrito académico.
8. Un posible artículo derivado de la tesis, enfocado en la comparación metodológica de modelos para detección temprana de contaminación atmosférica.

## 6. Herramientas computacionales

El proyecto se desarrollará principalmente en Python. Se utilizarán las siguientes herramientas:

- `pandas` y `numpy` para manipulación de datos.
- `matplotlib` y `seaborn` para visualización.
- `scipy` y `statsmodels` para análisis estadístico.
- `scikit-learn` para modelos de aprendizaje automático.

- `xgboost` o `lightgbm` para modelos de boosting.
- `ruptures` para detección de puntos de cambio.
- `hmmlearn` o librerías equivalentes para modelos ocultos de Markov.
- `PyTorch` o `TensorFlow/Keras` para autoencoders o redes neuronales.
- `Jupyter Notebook` para experimentación.
- $\text{\LaTeX}$  para la redacción de la tesis y del artículo.
- `Git` y `GitHub` para control de versiones.

## 7. Bases de datos

Se considerarán bases de datos abiertas y reales, tales como:

1. **Datos de calidad del aire de la Ciudad de México:** registros horarios de contaminantes provenientes del sistema de monitoreo atmosférico, incluyendo  $\text{PM}_{2.5}$ ,  $\text{PM}_{10}$ ,  $\text{O}_3$ ,  $\text{NO}_2$ ,  $\text{SO}_2$  y  $\text{CO}$ .
2. **OpenAQ:** plataforma internacional con datos abiertos de calidad del aire provenientes de múltiples ciudades y estaciones de monitoreo.
3. **NASA POWER:** datos meteorológicos y ambientales derivados de productos satelitales y modelos atmosféricos, útiles para obtener temperatura, humedad, radiación solar, precipitación y viento.
4. **NOAA o ERA5:** bases meteorológicas globales que pueden emplearse para complementar los datos locales con variables atmosféricas.
5. **Bases locales de redes de monitoreo ambiental:** en caso de trabajar con una ciudad o región específica, se podrán incorporar datos de redes oficiales de monitoreo.

La selección final dependerá de la disponibilidad, calidad, resolución temporal y cobertura espacial de los datos.

## 8. Posible contribución para artículo

El proyecto puede derivar en un artículo si se logra construir una comparación sólida y reproducible entre distintos enfoques de detección temprana. Una posible línea de contribución sería mostrar que los modelos que incorporan información multivariada y cambios de régimen detectan episodios extremos de contaminación con mayor anticipación y menor número de falsas alarmas que los métodos basados únicamente en umbrales.

El artículo podría estructurarse alrededor de las siguientes preguntas:

- ¿Qué métodos detectan con mayor anticipación episodios extremos de contaminación?
- ¿La inclusión de variables meteorológicas mejora la detección?
- ¿Los modelos de cambio de régimen ofrecen estados interpretables desde el punto de vista atmosférico?
- ¿Los métodos de aprendizaje automático superan significativamente a los modelos base?
- ¿Qué contaminantes o variables meteorológicas son más relevantes para anticipar eventos extremos?

## 9. Bibliografía básica

### Referencias

- [1] Hyndman, R. J. and Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*. OTexts.
- [2] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- [3] Murphy, K. P. (2012). *Machine Learning: A Probabilistic Perspective*. MIT Press.
- [4] Adams, R. P. and MacKay, D. J. C. (2007). Bayesian online changepoint detection. Technical report, University of Cambridge.
- [5] Basseville, M. and Nikiforov, I. V. (1993). *Detection of Abrupt Changes: Theory and Application*. Prentice Hall.
- [6] Chandola, V., Banerjee, A. and Kumar, V. (2009). Anomaly detection: A survey. *ACM Computing Surveys*, 41(3), 1–58.

- [7] Liu, F. T., Ting, K. M. and Zhou, Z.-H. (2008). Isolation Forest. In *Proceedings of the IEEE International Conference on Data Mining*, 413–422.
- [8] Rabiner, L. R. (1989). A tutorial on hidden Markov models and selected applications in speech recognition. *Proceedings of the IEEE*, 77(2), 257–286.
- [9] James, G., Witten, D., Hastie, T. and Tibshirani, R. (2013). *An Introduction to Statistical Learning*. Springer.
- [10] Goodfellow, I., Bengio, Y. and Courville, A. (2016). *Deep Learning*. MIT Press.